

## 算丰AI芯片的产品设计与安全设计

芯之安全磐石 若广厦之地基

比特大陆 汤炜伟





01 比特大陆简介

03) 算丰AI芯片的安全六盾

04) 他山之石:区块链





# 01 比特大陆简介





# 比特大陆公司历程

ANTMINER

#### 经过七年成长的高性能计算芯片设计企业: 掌握7纳米和5纳米芯片设计能力的全球几家公司之一

区块链业务-蚂蚁矿机

全球市场占有率第一





#### 人工智能业务——算丰

AI芯片和产品 / 深度学习专用TPU

2018

首款7nm芯片 第二代AI芯片

超50亿元 累计纳税额

第二款7nm芯片 第三代AI芯片

2019

2015

AI业务算丰启动

BTC.com矿池上线

2017

年营收突破

25亿美元

第一代AI芯片

2013

公司成立 推出55nm芯片



推出28nm芯片 ANTPOOL矿池上线

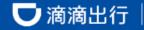


推出16nm芯片

2016









## 01) 比特大陆算丰AI芯片

2021

**BM1686** 

#### 高算力,大带宽

8核A53, 主控能力提高2~3倍

接口丰富,超低功耗

支持双干兆以太网口

功耗较上代产品降低50%以上

INT8算力17.6T / 35.2T



**BM1684** 

#### 强劲的视频编解码能力

- 最高支持38路1080P解码,提升4倍
- 视频前后处理能力提升4倍

### 安全可靠,完美保障

- 新增安全引擎,保证数据安全
  - 、算法模型安全、设备安全

2018

#### **BM1682**

工艺制程 峰值性能 28nm 3T FP32 视频解码 8路1080P硬解码

2019

#### **BM1880**

**BM1684** 

12nm

视频解码

工艺制程 峰值性能

32路1080P硬解码

17.6T/16W

工艺制程 峰值性能 1TOPS@INT8 28nm 视频解码 H.264解码



**BM1682** 

第二代面向云端与边缘 应用的AI推理芯片



**BM1880** 

第一代面向终端 应用的AI推理芯片 **BM1680** 

工艺制程 峰值性能 28nm 2T FP32

2016

组建AI芯片团队

2017









# AI芯片的设计初心





# **02** AI芯片的设计初心

Performance & Power

Application & Easy use

Lower cost & Safe

算力强、功耗适合 场景全覆盖 云端和边缘 机器视觉全算法支持 GPU迁移代价低 客户研发投入小 产品性价比优 客户数据安全 算法安全







## 全产品矩阵: 云和边缘全覆盖

**PeaceNet** 

算力云管理平台

算力资源池

算力调度/弹性伸缩

算法资源池

算法适配/算法仓库

应用网关

运营管理

**BMNNSDK** 

一站式开发工具链

Compiler 编译器

BMNetC / BMNetT / BMNetP / BMNetM / Paddle-Lite

Runtime 运行时部署工具

BMRuntime Engine / BMCV / OpenCV /FFMpeg / BMLib

#### 边缘



AI计算模组 SM5 算力 17.6TOPS@INT8



AI单芯加速卡 SC5H 算力 17.6TOPS@INT8



굸

AI三芯加速卡 SC5+ 算力 52.8TOPS@INT8



AI计算盒 SE5 算力 17.6TOPS@INT8



AI计算盒 SE3 算力 3TFLOPS@FP32



SC5+ AI服务器系列 X86平台,国产飞腾FT平台 一机多卡 AI超级算力中心 AI推理服务器集群 P级超强算力



BM1684 12nm 17.6TOPS@INT8



BM1682 28nm 3TFLOPS@FP32





## AI芯片的设计: ASIC专用架构, 算力、功耗、解码优于GPU

#### 高算力,大带宽

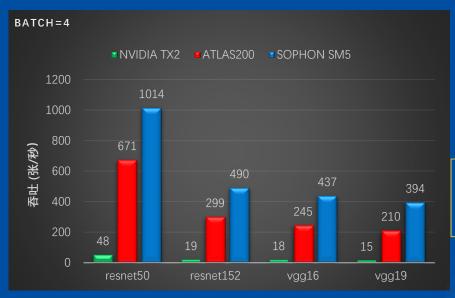
- 8核A53, 主控能力提高2~3倍
- INT8算力17.6T / 35.2T

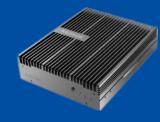


#### 强劲的视频编解码能力

- 最高支持38路1080P解码,提升4倍
- 视频前后处理能力提升4倍

- ResNet超过GPU 20倍
- VggNet超过GPU 25倍
- 能量效率超过旗舰 GPU 20倍



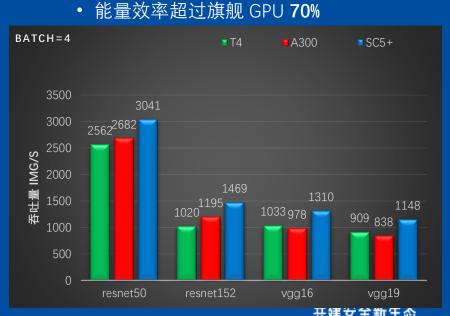


同等的被动散热 边缘盒/模组 (<20W)

高半长板卡 (<=75W)

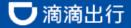


同等的的半



• ResNet超过旗舰 GPU 10%-32%

• VggNet超过旗舰 GPU **8%-41**%





## (02) AI芯片的设计初心: 机器视觉类AI算法全覆盖

图像分类

#### 典型模型

 AlexNet、GoogLeNet、VGGNet、 RESNET, DenseNet, mobilenet .....

## 目标检测



#### 典型模型

• YOLO、SSD、Fast R-CNN ......

#### 语义分割

语义分割:在语义上理解每个像素的角色



#### 典型模型

• Deeplab, FCN, SegNet .....

#### 实例分割

语义分割的基础上,实例分割将不同类型的



#### 典型模型

• Mask R-CNN、Deeplab ......

行业/技术	图像分类	目标检测	语义分割	实例分割
安防	人体车辆属性分类	人脸检测、目标检测	行为姿态检测	行为姿态检测
互联网	电商图像识别、OCR	内容审查	视频广告	视频广告
消费电子	手机相册分类	手机相册分类	手机美颜	抠图、电影效果
汽车	人车分类、红绿灯	人车检测	可行驶区域感知	可行驶区域感知
医疗	病灶标注	病灶识别与标注	CT、X光辅助诊断	CT、X光辅助诊断

# 02) AI芯片的设计初心:框架完善支持、易开发易迁移

应用层	人脸	数育 交通 表情 车辆 识别 识别	物流 智能 调度	零售 医疗 无人 影像 商店 识别	其他 
平台层	算力调度	算法管理	开放网关	运营服务	
算法层	视图处理	! 语音识别	语义分析	智能推荐	
框架层	Caffe	Tensor Flow	PyTorch	MxNet	Paddle 
基础层	服务器	芯	片	AI算力硬件	







## 算丰AI芯片的安全六盾







## 03) 最新一代AI芯片: BM1684的安全六盾



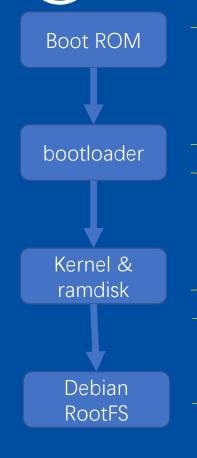
- Secure boot
- Crypto engines
- Secure key for customer
- Trust zone
- Secure firewall
- Chip unique ID





# 03

## 构建可信的系统: Secure boot 验证启动



片内固化 ARM trust firmware framework

- 从efuse读取root key digest,从SPI flash读取bootloader镜像和root key
- 用root key digest验证root key的合法性
- 用root key验证bootloader镜像的合法性

授信启动 U-boot verified boot framework

- bootloader镜像里包含了bootloader的code和public key
- 读取kernel + ramdisk的镜像
- 验证镜像的合法性

授信启动 Linux dm-verity

- ramdisk里包含了eMMC上根文件系统分区的root hash
- 采用了kernel的dm-verity机制,从root hash出发,对根文件系统做校验

Application

验证启动

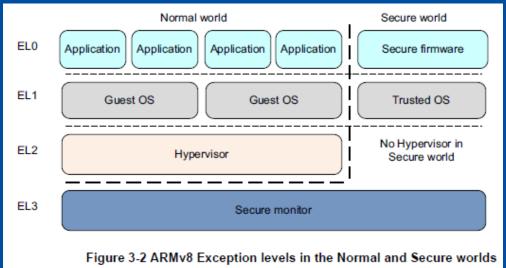
• 可采用非对称加密方法,对应用签名进行合法性验证







## 构建可信的系统: Trust zone 可信区



Normal World Secure World Client App Dynamic tee-Trusted supplicant App EE Client TEE Internal Generic TEE API (ioctl) User TEE subsystem Kernel Static OP-TEE **OP-TEE OP-TEE Msq** Trusted Trusted OS driver SMC call

- TrustZone提供一套高效系统安全保护硬件架构, 可以有效的抵御各种可能的攻击
- 它将SOC的资源划分为安全(secure world)和非安全(normal world)两个世界,关键的高敏感数据在安全世界执行,其它操作在正常世界执行
- 从芯片ROM开始,逐级建立信任链,每一步启动 都需要最高特权级别执行和密钥验证,防止软件 篡改替换
- BM1684遵循TrustZone设计规范进行了完整的实现



# 01

## 构建可信的系统: Secure Firewall & Secure key & Chip unique ID









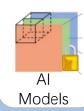
TEE Client API

Generic TEE API

Rich OS

#### Cust Trust Apps







TEE Internal APIs

Trusted OS

**TPU** 

**SPACC** 

OTP

...

#### • 应用密钥

- 客户根钥烧写至OTP区域,采用 secure mode保护,仅供硬件加解密 引擎读取
- 加密后应用密钥由normal world传入 secure world解密,用于相应数据的 解密

#### • 数据:

- 加密存储在非易失设备中 (eMMC/SDD/HDD)
- 使用时加载至secure world解密后使用
- 算法模型:
  - 加密存储在非易失设备中或由网络下发
  - 通过TA加载至secure world解密运行

Hardware Platform







## 构建可信的系统: Crypto Engines



- Support crypto engines:
  - AES/DES;
  - SM4/SHA;
  - RSA/ECC;
- All above hardware accelerator
  - SPACC enabled one way read
  - Software (cpu) accelerator can read both ways not secure
- Secure key storage scheme support







# 区块链设想





# 01 边缘计算安全体系

保密性和安全共享

数据完整性

数据加密性

数据安全

隐私保护

数据隐私保护

身份隐私保护

位置隐私保护

#### 边缘计算安全体系

边缘节点身份认证

云节点身份认证

节点身份管理

身份认证

访问控制

数据访问控制

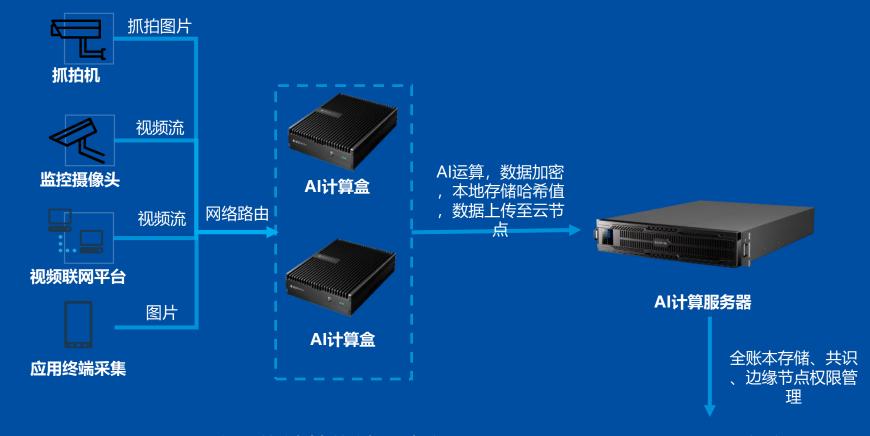
角色访问控制

身份访问控制



# 04

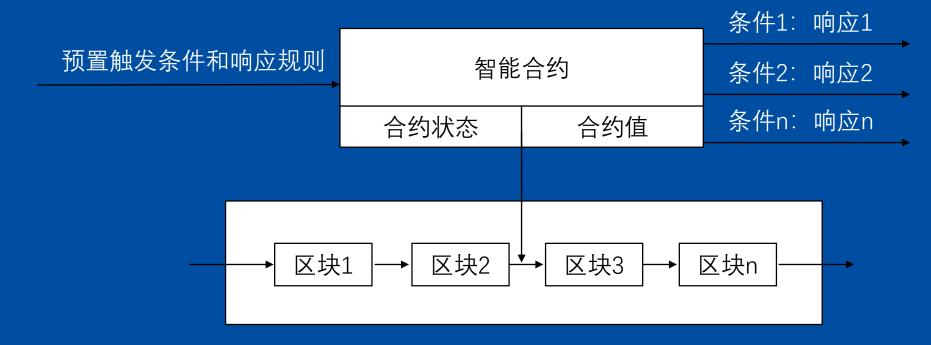
## 边缘计算典型网络节点和结构图



抓拍机、摄像头以及应用终端等终端节点负责采集数据,将数据通过网络路由上传到AI计算盒,边缘计算节点对终端采集的数据进行AI运算和处理,然后存储各个区块的哈希值。云节点负责账本存储、共识、路由和应用等任务, 云节点是云平台上划分的多个虚拟机, 虚拟机负责共识出块和全账本存储, 并可以通过开发区块链应用来管理和监控整个网络。

# 04

## 边缘计算和云: 基于区块链的智能合约



智能合约封装了预定义的触发条件及响应规则、触发合约执行的场景(如达到特定时间或发生特定事件等)、特定情境下的应对动作等。在边缘计算场景中,可以采用智能合约来操作数据,实现区块链数据的生成、修改、删除等权限管理功能,智能合约为区块链部署到AI硬件产品上提供了灵活可编程的机制和算法。





# 5 结语

- 比特大陆作为最早的AI芯片厂家之一,芯片设计和软件设计健全;
- 从最底层的芯片和硬件层,提供多种安全框架的产品解决方案;而 芯片级别的安全保护、隐私保护等是最基础的磐石;
- 以AI芯片构建的边缘计算方案,未来有机会通过区块链智能合约,构建安全认证和访问体系;
- 5G+AI时代来临,千亿级的物联网设备,安全问题会更加突出。我们愿与滴滴和各界朋友合作,打造一个具有算力之美的、安全的智能世界;







